

Guarani to spanish MT : Traduction automatique du guarani vers l'espagnol

Constance Sainte-Luce, Mickaëla Mastrodicasa, groupe 7

INALCO

Abstract

Ce mini-projet porte sur la traduction automatique du guarani vers l'espagnol et la comparaison de deux modèles multilingue sur un même corpus. Nous évaluons un modèle spécialisé dans les langues peu dotées et nous fine-tunons un modèle ne prenant pas en charge le guarani. Nous utilisons des métriques automatiques pour la partie évaluation des traductions effectuées. Les résultats montrent que M2M100 fine-tuné obtient de meilleures performances que NLLB-200. Ici, l'adaptation supervisée sur un corpus parallèle a permis de meilleurs résultats par rapport à un modèle multilingue connu pour gérer des langues peu dotées.

1. Introduction

Le guarani est une des deux langues officielles parlée au Paraguay (avec l'espagnol). Elle fait partie de la famille tupi-guarani et est aussi parlée dans le nord de l'Argentine, dans l'est de la Bolivie et dans le sud du Brésil. On estime le nombre de locuteurs à environ cinq millions dans le monde. Malgré le nombre de personnes qui le parle, le guarani reste considérée comme une langue à faibles ressources. Néanmoins, plusieurs outils de TAL ont été développés ces dernières années pour cette langue. Par exemple, le corpus Jojajovai que nous allons utiliser mais aussi d'autres corpus parallèles qui incluent la Bible guarani-espagnol ainsi que des textes (surtout des constitutions) issus du projet OPUS de l'université d'Helsinki collectant des documents multilingues. Ces corpus bilingues servent de base pour l'entraînement de modèles de traduction automatique comme NLLB-200, qui utilise environ 30 000 paires de phrases pour le guarani dans ses données d'entraînement.

Par ailleurs, un analyseur morphologique à états finis a été développé avec la technologie HFST (Helsinki Finite State Technology) spécifiquement pour le guarani paraguayen. Il a pour nom ParaMorfo et a été intégré dans Mainumby, un système de traduction expérimental guarani-espagnol développé à l'Université d'Indiana.

Concernant les ressources lexicales nous retrouvons un WordNet pour le guarani, la base de données lexicale TuLeD qui couvre 78 langues de la famille tupienne incluant le guarani et des treebanks de dépendances (TuDeT) qui ont été créés dans le framework Universal Dependencies pour neuf langues tupiennes.

2. Description du projet

L'objectif principal du devoir est de fine-tuner un système de traduction automatique pour qu'il puisse traduire des phrases du guarani vers l'espagnol, puis d'évaluer ce dernier. Mais ce n'est pas tout,

nous souhaitons aussi comparer les résultats de ce traducteur affiné à un autre modèle qui affirme prendre en charge le guarani. Ce qui nous intéresse ici c'est la capacité de modèles multilingues à apprendre à traduire une langue qui est absente de leur pré-entraînement mais aussi les limites des traducteurs affirmant pouvoir traduire certaines langues. En effet, bien que certains modèles récents annoncent le gérer, nous verrons dans la suite du rapport que cela peut être questionné, notamment à cause de traductions grammaticalement correctes mais sémantiquement incohérentes entre autre. Dans un premier temps, nous avons travaillé sur la préparation et le nettoyage des données. Puis nous avons expérimenté deux modèles de traduction multilingue. Le modèle NLLB-200, spécialisé dans les langues peu dotées, que nous avons testé directement sans entraînement afin d'évaluer ses performances sur le guarani qu'il annonce prendre en charge. Et le M2M100, un modèle multilingue généraliste que nous avons affiné sur notre corpus guarani-espagnol car ce modèle ne prend pas en charge le guarani de base. Enfin, les traductions produites par ces deux approches ont été évaluées à l'aide de métriques automatiques de traduction sur un jeu de test séparé.

3. Corpus

3.1. Description des données

Le corpus utilisé dans ce projet est *Jojajovai*. C'est un corpus parallèle guarani-espagnol aligné par phrase. Il contient environ 30 000 paires de phrases en guarani et sa traduction en espagnol. Ce corpus a été conçu en vue d'évaluations et de développements de systèmes de traduction automatique pour ces langues. Le corpus est libre d'accès. Dans ce dataset, nous retrouvons des articles de presse, de blog, des textes institutionnels, des transcriptions de séminaires et des textes issus de projets académiques. L'ensemble du corpus est déjà divisé en trois sous-parties. Nous

avons ainsi un jeu d'entraînement, un jeu de validation et un jeu de test. Au total, environ 20 000 paires sont destinées à l'entraînement, et un peu plus de 5 000 paires chacune sont réservées à la validation et au test. Il existe aussi un échantillon du jeu de test annoté manuellement par des locuteurs natifs du guarani. Ces annotations portent sur le dialecte de guarani présent dans la phrase et la qualité de l'alignement entre la phrase guarani et la phrase espagnole. Pour l'alignement, quatre catégories sont utilisées. Ces catégories vont de A qui représente la note attribuée aux paires parfaitement correspondantes à D qui est donné aux paires ne correspondant pas du tout. Cependant ces annotations ne couvrent qu'un sous-ensemble du corpus. Le corpus est fourni sous la forme d'un fichier CSV, `jojajovai_all.csv`, qui contient pour chaque paire la source du texte, la partition à laquelle elle appartient et les deux phrases alignées. Un second fichier, `jojajovai_sample_annotations.csv`, contient les annotations manuelles associées à l'échantillon du jeu de test. Ainsi, Jojajovai constitue la base de données pour l'évaluation de modèles de traduction automatique guarani-espagnol.

3.2. Prétraitement

Avant l'entraînement et l'évaluation des modèles, nous avons effectué un prétraitement automatique en Python à l'aide du script `clean_all.py`. Les textes ont d'abord été normalisés afin d'unifier les encodages et les espaces. Les paires contenant des phrases vides ont été supprimées. Nous avons tokenisé les phrases pour éliminer les exemples trop courts ou trop longs et un filtrage basé sur le rapport de longueur entre les phrases guarani et espagnol a permis de retirer les paires trop déséquilibrées. Pour exclure les phrases se trouvant être trop proches l'une de l'autre en termes de traduction (en cas d'erreur d'alignement ou une duplication par exemple), nous avons utilisé une mesure de similarité lexicale. Enfin, nous avons aussi vérifié l'absence de fuite de données entre les jeux d'entraînement, de validation et de test.

4. Modèles

Nous utilisons deux modèles de traduction automatique pour ce mini-projet, M2M100 et NLLB-200, tous deux développés par Meta et diffusés via la bibliothèque Transformers de Hugging Face. Ils reposent sur des architectures de type encodeur-décodeur et utilisent des mécanismes d'attention pour modéliser les relations entre les mots de la phrase source et de la phrase cible.

4.1. M2-M100

Le premier modèle utilisé est M2M100 (voir script `train_m2m100.py`). Il s'agit d'un modèle de traduction multilingue qui traduit directement entre plus de cent langues, sans passer par l'anglais comme langue pivot. En effet de nombreux traducteurs utilisent souvent l'anglais comme langue intermédiaire mais cette technique peut entraîner une perte d'information sémantique. M2M100 est un modèle de type sequence-to-sequence basé sur une architecture Transformer avec un encodeur et un décodeur empilant plusieurs couches d'attention multi-têtes et de réseaux feed-forward. Chaque langue est contrôlée par des tokens de langue spécifiques qui indiquent au modèle la langue source et la langue cible. Dans le cadre de notre travail, M2M100 est utilisé après fine-tuning sur le corpus Jojajovai. Comme le guarani ne fait pas partie des langues prise en charge par M2M100, nous avons utilisé un alias de langue. Cette idée nous a été suggérée par un doctorant travaillant sur la même problématique avec qui nous avons discuté de notre projet. En fait, une étiquette de langue existante parmi celles traitées par le modèle (ici l'anglais) est utilisée comme substitut pour représenter le guarani. Lors de l'entraînement, le modèle apprend à associer cette étiquette à des phrases en guarani et à produire une traduction en espagnol.

4.2. NLLB-200

Le second modèle étudié est NLLB-200 (voir script `eval_nllb.py`) qui est spécialisé dans la traduction de langues peu dotées. Comme son nom l'indique, il couvre 200 langues dont le guarani et l'espagnol qui sont intégrées directement dans son vocabulaire et dans ses données de pré-entraînement. NLLB-200 repose également sur une architecture Transformer encodeur-décodeur. Le modèle utilise lui aussi un contrôle des langues via des codes normalisés pour pouvoir spécifier les langues sources et cibles de traduction. Dans ce travail, NLLB-200 est utilisé sans affinement sur le corpus Jojajovai. L'objectif est d'évaluer ses performances telles quelles sur la traduction guarani-espagnol, afin de créer un point de comparaison avec le modèle M2M100 fine-tuné. Nous avons faits des tests préliminaires très basiques, d'abord sur des paires de langues bien couvertes comme l'anglais vers le français. Ce sont nos témoins de l'expérience en quelque sorte et donc très naturellement ces tests ont donné des traductions conformes aux attentes. Puis nous avons effectué des tests avec des phrases en guarani. Bien que le modèle produise des phrases grammaticalement correctes dans la langue cible, les traductions semblaient avoir des soucis en terme de sémantique.

Exemple (traduction guarani vers français et espagnol).

Source (GN). Omopotĩvo hikuái tetãme vicio política, ko'ã itaugüeño he'íva ombotovévo pokarême umi elemento omopotĩva.

Traduction (FR). Lorsqu'ils ont nettoyé le pays des vices politiques, ces sculpteurs ont déclaré qu'ils rejetaient la pureté des éléments qui le nettoyaient.

Traduction (ES). En la limpieza del país de los vicios políticos, los funcionarios dicen que rechazan la limpieza de los elementos limpiadores.

Les traductions produites sont toutes les deux bonnes sur le plan grammatical même si par exemple le choix du terme "sculpteurs" dans la phrase française n'a pas vraiment de sens dans le contexte. De plus, nous voyons clairement qu'en traduisant la même phrase en guarani vers le français et puis du guarani vers l'espagnol, nous n'avons pas les mêmes termes malgré la proximité de ces deux langues. En espagnol, on garde un peu plus de contexte avec le mot *funcionarios*, mais il reste tout de même un problème de sens. D'après ce type de sortie, nous pouvons nous attendre à ce que le modèle puisse produire des phrases bien formées mais qu'il puisse aussi rencontrer des difficultés à capturer les aspects plus sémantiques. Comme nous ne maîtrisons pas le guarani, il est difficile de déterminer exactement l'erreur. Cependant, la traduction laisse supposer un problème d'interprétation. L'angle que nous souhaitons aborder dans ce rapport est donc une approche comparative des deux modèles, un supposé connaître le guarani et un autre entraîné à le reconnaître.

5. Évaluation

L'évaluation des systèmes de traduction est réalisée à l'aide de métriques automatiques. En effet, nous allons comparer les phrases générées par les modèles aux traductions de référence présentes dans le corpus de test. Nous utilisons ainsi BLEU, chrF et TER.

5.1. BLEU

Le score BLEU repose sur la comparaison des n-grammes de mots entre la traduction produite par le modèle et la traduction de référence. Plus BLEU est élevé, plus la sortie du modèle est proche de la référence. Cependant cette métrique est sensible aux variations de lexique et aux différences de segmentation.

5.2. chrF

Contrairement à BLEU, chrF compare les traductions au niveau des caractères et non des mots. C'est une mesure adaptée aux langues pour lesquelles l'orthographe peut varier. Un score chrF élevé indique que la traduction générée partage une grande similarité de forme avec la référence même si les mots ne correspondent pas exactement.

5.3. TER

Cette mesure estime le nombre d'opérations nécessaires pour transformer la traduction produite par le modèle en la traduction de référence. Le score TER s'interprète comme un taux d'édition, et plus il est faible, meilleure est la traduction. Elle évalue l'effort requis pour corriger automatiquement la sortie du système, afin de reproduire une correction humaine.

6. Résultats

Modèle	BLEU	chrF	TER
NLLB-200	29.85	53.03	63.15
M2M100	31.04	53.02	61.30

Table 1: Scores de traduction des modèles NLLB-200 et M2M100.

6.1. NLLB-200

NLLB-200 obtient un score BLEU de 29.85, un score chrF de 53.03 et un TER de 63.15. Nous pouvons interpréter ces résultats comme le fait que le modèle est capable de produire des traductions globalement correctes mais qui restent souvent éloignées des références par rapport aux choix lexicaux. Ce résultat fait écho avec les observations qualitatives réalisées lors des tests exploratoires, où certaines traductions apparaissaient grammaticalement correctes mais ambiguës ou maladroites sur le plan du sens.

6.2. M2-M100

Le modèle M2M100 atteint un score BLEU de 31.04, un score chrF de 53.02 et un TER de 61.30. Le gain en BLEU est modéré mais indique tout de même que les traductions produites par M2M100 sont plus proches lexicalement des phrases de référence. La baisse du TER montre également que les sorties nécessitent moins de corrections pour être acceptables.

6.3. Observations globales

Le score chrF reste quasiment identique entre les deux modèles. Cela signifie que les deux systèmes produisent déjà des formes espagnoles correctes sur le plan orthographique et morphologique. Les améliorations apportées par le fine-tuning concernent donc moins la forme que l'alignement traductionnel et le choix des mots. Cependant l'augmentation du score BLEU ne garantit pas que toutes les traductions soient meilleures. Comme expliqué précédemment, de par sa nature BLEU peut sous-estimer des traductions fidèles mais formulées différemment ou même surévaluer des phrases un peu à côté au niveau du sens. Néanmoins M2M100 ne prend pas officiellement en charge le guarani mais l'utilisation d'un alias lors du fine-tuning lui a permis d'apprendre des correspondances entre le guarani et l'espagnol. À l'inverse, NLLB-200 annonce un support natif du guarani, mais celui-ci semble rester superficiel dans la pratique. Finalement M2M100 fine-tuné obtient de meilleures performances que NLLB-200 utilisé sans adaptation sur deux métriques sur trois.

7. Discussion

Les résultats obtenus montrent que notre fine tuning peut apporter des gains mesurables pour la traduction du guarani vers l'espagnol, même lorsque la langue source n'est pas prise en charge nativement par le modèle. Cependant, le cadre restreint du projet fait que nous avons effectués plusieurs choix méthodologiques, notamment en ce qui concerne le nettoyage des données, l'absence d'évaluation humaine et les limites liées à notre propre connaissance linguistique du guarani.

7.1. Axes d'améliorations

En parallèle de l'analyse du corpus Jojajovai complet (jojajovai_all.csv), nous avons commencé un premier travail exploratoire sur le sous-ensemble annoté manuellement (jojajovai_sample_annotation.csv). Nous voulions essayer de nous appuyer sur ces annotations pour filtrer automatiquement l'ensemble des 30 000 paires de phrases. Nous avons procédé à un nettoyage (clean_annot.py) pour avoir un gold standard en gardant les phrases identifiées comme du guarani uniquement (et pas les autres dialectes donc pas le jehe'a ni le jopara). De plus, nous avons supprimé les paires de phrases catégorisées D. Toutefois, le nettoyage de ce sous-ensemble déjà petit (400 phrases alignées et annotées) a encore davantage réduit sa taille (plus que 250 phrases environ). Nous ne pouvions donc pas utiliser ce dataset pour affiner nos modèles. De plus, en l'absence de compétences linguistiques en guarani,

il nous a semblé risqué de généraliser directement ces critères au corpus complet sans validation externe d'un locuteur de la langue au moins. Nous pouvons considérer cette idée comme une piste d'amélioration possible pour des travaux futurs. Intégrer une collaboration avec des locuteurs natifs ou des linguistes spécialistes du guarani pourrait permettre l'automatisation du filtrage sur un plus grand corpus comme le nôtre. Lors de la phase de nettoyage, nous avons également été confrontés à la question de la tokenisation du guarani. Contrairement au français ou à l'espagnol, le guarani est une langue agglutinante, dans laquelle les espaces ne correspondent pas nécessairement à des unités linguistiques comparables aux mots des langues indo-européennes. Dans ce contexte, toute tokenisation naïve basée uniquement sur les espaces ou la ponctuation peut découper artificiellement des unités morphologiques ou au contraire fusionner des éléments qui devraient être distingués. Ici, la tokenisation a été utilisée uniquement à des fins heuristiques (détection de paires copiées, estimation de ratios de longueur), et pas comme entrée directe du modèle de traduction. M2M100 repose quant à lui sur sa propre segmentation interne avec SentencePiece qui est faite exprès pour être indépendante des conventions d'espacement propres à chaque langue. Néanmoins, une amélioration possible du projet consisterait à utiliser une tokenisation spécifiquement adaptée au guarani ou intégrer des ressources morphologiques existantes pour mieux respecter la structure de la langue lors des phases de filtrage et d'analyse.

8. Conclusion

Pour conclure, en comparant un modèle multilingue spécialisé utilisé sans adaptation et un modèle généraliste affiné sur un corpus parallèle, nous avons montré que le fine-tuning supervisé peut compenser en partie l'absence de support natif d'une langue. Les résultats obtenus soulignent l'importance de la qualité des données et de l'adaptation ciblée des modèles, parfois plus déterminantes que la couverture linguistique annoncée lors du pré-entraînement. Enfin, nous avons aussi vu les limites des évaluations automatiques et l'intérêt de futures analyses plus qualitatives et collaboratives pour mieux appréhender la traduction de langues peu représentées.

9. Annexe

jojajovai sample annotation

source	gn	es	dialect_annotator_1	dialect_annotator_2	dialect_annotator_3	dialect_unified
blogs	– Namendaséi haguére –he'ë ári ombohováí–.	– Porque no quería casarme –le respondió sobre sus palabras–.	guarani	guarani	guarani	guarani
anlp	Upe mitã renda oipe'ã hokê opa ára mitã imitãvéva po arýguipe guará.	La guardería está abierta todos los días para niños menores de cinco años solamente.	guarani	guarani	guarani	guarani
spl	Omba'apóta subcomisión-kuéra ypykuéra he'ëíta aty pegua.	Reunión de trabajo de subcomisiones de lenguas indígenas.	jehe'a	jehe'a	jehe'a	jehe'a
libro_gn	Oñehesa 'yijo jave he'ëaty oñembyatyva ha oñemoñe'ëasa jave he'ë pyahu, ojejesarekôta he'ëipa hina upe he'ëiséva he'ëisehaichaite .	En el análisis de las unidades terminológicas recogidas y en la traducción de nuevos términos, se tendrá en cuenta la funcionalidad de las distintas propuestas .	guarani	guarani	guarani	guarani

Figure 1: Extrait du corpus Jojajovai annoté

split	source	gn	es
train	abc	Itaugua omokyre'y "omopoti" Congreso	En Itauguá promueven "limpiar" el Congreso
train	abc	Omopotivo hikuái tetáme vicio política, ko'ã itaugueño he'íva ombotovévo pokarême umi elemento omopotíva.	Con el propósito de limpiar al país de los vicios de la política, los itaugueños expresan su repudio a los corruptos con elementos de limpieza.
train	abc	Ko'ã 50 tapicha oñembyaty parroquia Virgen del Rosario plazoletape ko distrito oñemanifestávo político pokarême.	Unas 50 personas se encuentran en la plazoleta de la parroquia Virgen del Rosario de este distrito manifestando su repudio hacia los políticos corruptos.

Table 2: Exemples de paires de phrases guarani-espagnol.

10. Bibliographie

- Allen Institute for AI and Hugging Face. 2026. [al-lenai/nllb \(dataset card\)](#). Hugging Face dataset card. Accessed 2026-01-14.
- Luis Chiruzzo, Marvin Agüero-Torales, Aldo Alvarez, and Yliana Rodríguez. 2023. [Initial experiments for building a Guarani WordNet](#). In *Proceedings of the 12th Global Wordnet Conference*, pages 197–204, University of the Basque Country, Donostia - San Sebastian, Basque Country. Global Wordnet Association.
- Luis Chiruzzo, Santiago Góngora, Aldo Alvarez, Gustavo Giménez-Lugo, Marvin Agüero-Torales, and Yliana Rodríguez. 2022. [Jojajovai: A Parallel Guarani-Spanish Corpus for MT Benchmarking](#). In *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, pages 2107–2117, Marseille, France. European Language Resources Association.
- Marta R. Costa-jussà, James Cross, Onur Çelebi, Maha Elbayad, Kenneth Heafield, Xianli He, Ye Jia, Yunsu Kim, Philipp Koehn, Yixin Lin, Jordan Liu, Zhiqiang Liu, Xutai Ma, Aurélie Névoul, Chikashi Nobata, Juan Pino, Holger Schwenk, Minjoon Seo, Xian Tang, Toan Tran, Gonzalo Verdú Montero, Changhan Wang, Shuo Wu, Taedong Yi, Qian Zhang, Haoyang Zhou, and Luke Zettlemoyer. 2022. [No language left behind: Scaling human-centered machine translation](#). *arXiv*.
- Emergent Mind. 2026. [Emergent mind topic: Spanish-Guarani dataset](#). Web page. Accessed 2026-01-14.
- Angela Fan, Shruti Bhosale, Holger Schwenk, Zhiyi Ma, Ahmed El-Kishky, Siddharth Goyal, Man-deep Baines, Onur Celebi, Guillaume Wenzek, Vishrav Chaudhary, Francisco Guzmán, Sergey Edunov, Edouard Grave, Michael Auli, and Armand Joulin. 2020. [Beyond English-centric multilingual machine translation](#). *arXiv*.
- Hugging Face. 2026. [Transformers documentation: M2M100](#). Online documentation. Accessed 2026-01-14.
- LT4All organizers. 2025. [LT4All 2025 page \(sciencesconf.org\)](#). Conference web page. Accessed 2026-01-14.
- Meta and Hugging Face. 2022. [facebook/nllb-200-3.3b \(model card\)](#). Hugging Face model card. Accessed 2026-01-14.
- Meta and Hugging Face. 2026. [facebook/nllb-200-distilled-600m \(model card\)](#). Hugging Face model card. Accessed 2026-01-14.
- mmaguero. 2026. [josa-corpus \(github repository\)](#). GitHub repository. Accessed 2026-01-14.
- pywirrarika. 2026. [naki \(github repository\)](#). GitHub repository. Accessed 2026-01-14.
- See arXiv record for full author list. 2024. [arxiv preprint 2404.08368](#). *arXiv*.
- Unknown. 2026. [Upm repository pdf \(id: 10242748\)](#). Online PDF. Accessed 2026-01-14.